

UNIVERSITÉ KOFI ANNAN DE GUINÉE

Master 1 — Cours de Fouille de Données

PRÉDICTION DU RISQUE DE PALUDISME SELON LES CONDITIONS ENVIRONNEMENTALES

Étude synthétique sur les régions administratives de la Guinée — Année
2025

Rapport de projet — Méthodologie CRISP-DM

Étudiant(e) en Master 1
Année académique 2025-2026

AVERTISSEMENT

Le jeu de données utilisé est synthétique et ne constitue pas une source sanitaire officielle.

Résumé exécutif

Ce projet applique la méthodologie CRISP-DM à la classification du niveau de risque de paludisme en Guinée. L'objectif est de produire une estimation exploratoire — faible, moyen ou élevé — à partir de variables météorologiques, géographiques et environnementales. Le cas d'usage envisagé est l'anticipation des périodes susceptibles d'augmenter la demande de consultation dans les centres de santé.

Le fichier analysé contient 5,000 observations et 24 colonnes d'origine, couvrant la période du 2025-01-01 au 2025-12-31. Il comprend les 8 régions administratives et 34 localités préfectorales représentées dans le CSV. Aucune valeur manquante ni aucun doublon complet n'a été détecté dans l'audit initial.

Trois modèles ont été comparés avec une séparation stratifiée 80/20 : régression logistique, Random Forest et XGBoost. Dans cette expérimentation, le meilleur F1 pondéré est obtenu par **XGBoost** (0.928), suivi de la régression logistique (0.927). Ces résultats élevés doivent être interprétés avec prudence, car le CSV est synthétique et le risque a été construit à partir de facteurs environnementaux simulés.

Plan du rapport

Partie	Contenu
1	Compréhension métier et objectifs
2	Compréhension et qualité des données
3	Préparation et prévention de la fuite de données
4	Modélisation et évaluation
5	Interprétation, recommandations et limites
6	Déploiement, reproductibilité et références

1. Compréhension métier

1.1 Problématique

Le paludisme reste une maladie fortement influencée par le contexte climatique et environnemental. Les précipitations, l'humidité, la présence d'eau stagnante et la température peuvent modifier les conditions de développement des vecteurs. Dans ce projet, on cherche à répondre à la question suivante :

Comment estimer le niveau de risque de paludisme par période et par territoire afin d'aider un centre de santé à anticiper les pics de consultation ?

1.2 Objectifs

- Construire une base d'analyse au niveau des régions et préfectures de Guinée pour l'année 2025.
- Décrire les distributions des variables météorologiques et environnementales.
- Comparer plusieurs algorithmes de classification supervisée.
- Identifier les facteurs environnementaux associés aux décisions du modèle.
- Fournir une base reproductible pour un futur tableau de bord Streamlit.

1.3 Décisions potentiellement éclairées

Une alerte de niveau élevé pourrait aider à anticiper les stocks de tests et de traitements, organiser les équipes et renforcer les actions de sensibilisation. Le modèle ne remplace pas un diagnostic médical ni un système officiel de surveillance : il servirait uniquement d'outil d'aide à l'anticipation, après validation par les autorités sanitaires.

1.4 Critères de réussite

1. Respecter une séparation stricte entre apprentissage et test.
2. Comparer au moins trois modèles avec des métriques adaptées au multiclassés.
3. Éviter l'utilisation de variables qui révèlent directement la cible.
4. Interpréter les résultats avec transparence compte tenu du caractère synthétique des données.

2. Compréhension des données

2.1 Source et périmètre

Le fichier `paludisme\_1786569715919.csv` a été fourni dans le projet. Il représente un jeu de données synthétique préparé pour l'exercice. Sa structure reprend le contexte du sujet P06 : conditions météo, contexte géographique et classe de risque. Les données ne doivent pas être citées comme des observations OMS, HDX ou Open-Meteo réellement téléchargées.

Élément	Valeur
Nombre de lignes	5,000
Période	2025-01-01 — 2025-12-31
Régions administratives	8
Préfectures/localités	34
Valeurs manquantes	0
Doublons complets	0
Variable cible	niveau_risque

2.2 Dictionnaire synthétique des variables

Groupe	Variables principales	Rôle
Identification	id_observation, date, annee, mois, semaine	Repérage temporel et traçabilité
Géographie	region_administrative, prefecture, latitude, longitude	Localisation de l'observation
Climat	temperature_moyenne_c, temperature_min_c, temperature_max_c	Conditions thermiques
Pluie	precipitation_mm, precipitation_7j_mm, precipitation_30j_mm, jours_pluie_7j	Humidité et accumulation des pluies
Environnement	humidite_relative_pct, humidite_sol_pct, indice_eau_stagnante	Conditions favorables aux vecteurs
Cible	niveau_risque	faible, moyen ou eleve
Contrôle	cas_paludisme_simules, taux_incidence_simule_pour_1000	Résultats simulés, exclus du modèle

2.3 Analyse exploratoire

La distribution de la cible est déséquilibrée mais les trois classes sont représentées. La classe faible est majoritaire, suivie de la classe élevée et de la classe moyenne. Cette structure justifie l'utilisation d'une pondération des classes lors de l'apprentissage.

Niveau	Effectif	Proportion
faible	2,157	43.1%
eleve	1,608	32.2%
moyen	1,235	24.7%




Figure 1 — Répartition de la variable cible.




Figure 2 — Répartition relative du risque par région.

3. Préparation des données

3.1 Nettoyage et transformations

5. Lecture du CSV avec encodage UTF-8 compatible avec les accents.
6. Conversion de la date en type datetime et création de la variable jour_annee.
7. Vérification des valeurs manquantes et des doublons.
8. Séparation de la cible niveau_risque et encodage des classes avec LabelEncoder.
9. Imputation médiane des variables numériques et imputation par la modalité la plus fréquente pour les catégories.
10. Standardisation des variables numériques et One-Hot Encoding des variables catégorielles.

3.2 Prévention de la fuite de données

Les variables ``cas_paludisme_simules`` et ``taux_incidence_simule_pour_1000`` sont explicitement exclues. Elles décrivent des résultats sanitaires simulés qui sont trop proches de la construction de la classe ``niveau_risque``. Les conserver aurait artificiellement gonflé les performances et ne correspondrait pas à une prédiction anticipée basée uniquement sur l'environnement.

Le préprocesseur est ajusté uniquement sur le sous-ensemble d'entraînement à l'intérieur de pipelines scikit-learn. Le jeu de test est donc conservé pour une évaluation finale indépendante.

3.3 Variables utilisées

Les variables numériques comprennent le mois, la semaine, les coordonnées, les températures, les précipitations, l'humidité, le vent, les jours de pluie, l'humidité du sol, l'indice d'eau stagnante et le jour de l'année. Les variables catégorielles sont la région administrative, la préfecture et la zone climatique.




Figure 3 — Corrélations entre variables numériques.

4. Modélisation

4.1 Protocole expérimental

Les données ont été séparées en 80 % pour l'entraînement et 20 % pour le test avec stratification sur la variable cible. La graine aléatoire 42 est utilisée pour rendre l'expérience reproductible. La pondération `balanced` est appliquée à la régression logistique et à la forêt aléatoire ; XGBoost reçoit des poids d'observation calculés à partir de la distribution d'entraînement.

4.2 Algorithmes

Modèle	Principe	Intérêt
Régression logistique	Modèle linéaire multiclassés	Référence interprétable et rapide
Random Forest	Ensemble d'arbres avec agrégation	Capte des relations non linéaires et fournit des importances
XGBoost	Boosting d'arbres successifs	Modèle performant sur des relations complexes

4.3 Métriques

- Accuracy : proportion globale de prédictions correctes.
- Précision : proportion des alertes d'une classe qui sont correctes.
- Rappel : capacité à retrouver les observations réellement présentes dans une classe.
- F1 : compromis entre précision et rappel.
- ROC-AUC OvR pondéré : capacité de séparation multiclassés, calculée en approche one-vs-rest.

4.4 Résultats comparatifs

Modèle	Accuracy	Précision	Rappel	F1	ROC-AUC
Régression logistique	0.926	0.928	0.926	0.927	0.991
Random Forest	0.916	0.922	0.916	0.918	0.990
XGBoost	0.927	0.929	0.927	0.928	0.991

Selon le F1 pondéré, le meilleur modèle sur cette exécution est **XGBoost**. La différence avec la régression logistique est faible : il est donc important de ne pas choisir un modèle uniquement sur l'accuracy. Pour une utilisation sanitaire, le rappel de la classe `leve` et le coût des faux négatifs devraient être analysés séparément avant toute décision.




Figure 4 — Comparaison des métriques sur le jeu de test.

4.5 Lecture des performances

- La régression logistique fournit une excellente référence et reste plus simple à expliquer.
- Random Forest obtient un score légèrement inférieur dans cette configuration, mais garde un intérêt pour l'analyse des interactions.
- XGBoost arrive en tête sur le F1 pondéré, sans que cet écart suffise à démontrer une supériorité dans un contexte réel.
- Les performances élevées sont cohérentes avec le fait que la classe synthétique a été construite à partir de variables environnementales présentes dans le fichier.

4.6 Matrice de confusion

La matrice de confusion du meilleur modèle permet de distinguer les erreurs entre les niveaux faible, moyen et élevé. Dans un système d'alerte, les confusions entre `moyen` et `eleve` doivent être examinées avec une attention particulière, car elles influencent directement la préparation des ressources.




Figure 5 — Matrice de confusion du modèle XGBoost.

4.7 Variables importantes

L'analyse d'importance de XGBoost place l'indice d'eau stagnante en première position, suivi par les précipitations cumulées sur 7 jours. La zone climatique, les précipitations sur 30 jours et certaines variables géographiques viennent ensuite. Cette lecture est cohérente avec l'hypothèse métier, mais une importance de modèle ne prouve pas à elle seule une causalité médicale.

Variable transformée	Importance
indice_eau_stagnante	0.205
precipitation_7j_mm	0.090
zone_climatique_montagneux	0.080
precipitation_30j_mm	0.062
region_administrative_Labé	0.043
prefecture_Koundara	0.027
latitude	0.025
region_administrative_Kindia	0.022
prefecture_Boké	0.021
region_administrative_Mamou	0.019

5. Interprétation et recommandations

5.1 Interprétation métier

Le modèle suggère que les indicateurs d'accumulation de pluie et d'eau stagnante sont particulièrement utiles pour distinguer les niveaux de risque dans le jeu synthétique. Les régions forestières et côtières présentent également des profils distincts dans les variables simulées. Ces résultats peuvent servir à formuler des hypothèses pour une collecte réelle, mais ils ne doivent pas être utilisés pour classer une population ou déclencher seuls une intervention.

5.2 Recommandations opérationnelles

11. Mettre en place une validation avec des données sanitaires réelles et datées provenant des services compétents.
12. Ajouter des variables retardées : consultations des semaines précédentes, couverture des campagnes, accès aux soins et densité de population.
13. Évaluer explicitement le rappel de la classe élevée et définir un seuil d'alerte selon le coût des faux négatifs.
14. Comparer les performances par région et par préfecture afin de repérer les zones où le modèle généralise moins bien.
15. Documenter chaque nouvelle version du jeu de données et du modèle dans GitHub avec des messages de commit explicites.

5.3 Gouvernance et éthique

- Ne pas présenter le CSV synthétique comme une mesure officielle de l'incidence du paludisme.
- Ne pas utiliser le modèle pour un diagnostic individuel.
- Protéger les données de santé réelles et supprimer toute information directement identifiante.
- Faire valider les indicateurs et les seuils par des professionnels de santé publique.

6. Déploiement et reproductibilité

6.1 Structure recommandée du dépôt

Dossier/fichier	Rôle
README.md	Contexte, installation, méthode, résultats et limites
data/raw/	Données brutes ou liens vers les sources
data/processed/	Données nettoyées et prêtes pour l'analyse
notebooks/	Notebook d'exploration et notebook de modélisation
src/	Prétraitement, entraînement et prédiction
models/	Modèles sérialisés après validation
app/app.py	Application Streamlit locale
rapport/	Rapport final et ressources visuelles

6.2 Application Streamlit envisagée

Une application Streamlit pourrait permettre de sélectionner une région, une préfecture et des conditions météorologiques, puis d'afficher la classe de risque estimée. L'interface devrait présenter une mention claire sur la nature expérimentale du modèle, les variables utilisées et la date de mise à jour des données.

6.3 Reproduction de l'analyse

16. Placer le CSV et le notebook dans le même dossier, ou adapter DATA_PATH.
17. Installer pandas, numpy, matplotlib, seaborn, scikit-learn et xgboost.
18. Exécuter les cellules dans l'ordre sans modifier la séparation train/test.
19. Conserver le tableau `results\_df`, les matrices de confusion et l'analyse d'importance.
20. Documenter la version des packages et la graine aléatoire utilisée.

Conclusion générale

Ce travail a permis de construire un pipeline complet de classification supervisée selon CRISP-DM, depuis la compréhension métier jusqu'à l'interprétation des modèles. Le notebook associé est directement adapté au CSV fourni et compare trois algorithmes demandés dans le cahier des charges. L'analyse met en avant l'intérêt des précipitations cumulées, de l'humidité et de l'indice d'eau stagnante dans la séparation des classes synthétiques.

La conclusion principale est méthodologique : avant de rechercher le modèle le plus complexe, il faut s'assurer de la qualité du protocole, de l'absence de fuite de données et de l'adéquation des métriques à la décision métier. Une étape ultérieure devra remplacer les données synthétiques par des données validées, recalibrer le modèle et organiser une évaluation avec les utilisateurs de terrain.

Références et sources consultées

21. Université Kofi Annan de Guinée, Catalogue de projets individuels — Fouille de Données M1, année académique 2025-2026, sujet P06.
22. Fichier fourni : paludisme_1786569715919.csv, jeu synthétique utilisé pour cette étude.
23. Notebook fourni : churnML_1786568192001.ipynb, consulté comme exemple de structure d'analyse et de comparaison de modèles.
24. Brief fourni dans le projet : consignes CRISP-DM et structure recommandée du dépôt GitHub.
25. Sources envisagées dans le brief, à vérifier avant utilisation réelle : OMS/HDX pour les données sanitaires et Open-Meteo pour les historiques météorologiques.

Annexe — rappel des fichiers livrés

Fichier	Description
paludisme_1786569715919.csv	Jeu de données synthétique de 5 000 observations
paludisme_meteo_guinee_2025_adapte.ipynb	Notebook d'exploration et de modélisation
rapport_paludisme_guinee_2025.docx	Présent rapport Word