

UNIVERSITÉ KOFI ANNAN DE GUINÉE

Master 1 - Cours de Fouille de Données

**PRÉDICTION DU RISQUE DE PALUDISME
SELON LES CONDITIONS ENVIRONNEMENTALES**

Mon étude sur les régions administratives de la Guinée - Année 2025
Rapport de projet personnel - Méthodologie CRISP-DM

Ibrahima Sory Barry

**Professeur chargé du cours:
Monsieur Youssouf Vessou Traoré**

Résumé exécutif

Ce rapport présente le travail que j'ai mené dans le cadre de mon projet de Master 1, en appliquant la méthodologie CRISP-DM à un problème de classification : estimer le niveau de risque de paludisme en Guinée à partir de variables météorologiques, géographiques et environnementales. Mon objectif n'était pas de produire un outil médical opérationnel, mais de construire, étape par étape, un pipeline d'analyse rigoureux, de la compréhension du problème jusqu'à l'interprétation des résultats, en essayant de rester honnête sur ce que le modèle peut réellement dire et sur ce qu'il ne peut pas dire.

Le cas d'usage que j'ai retenu est celui d'un centre de santé qui chercherait à anticiper les périodes où la demande de consultation pour paludisme risque d'augmenter, en fonction des conditions environnementales observées.

Le fichier que j'ai analysé contient 5 000 observations et 24 colonnes d'origine, couvrant toute l'année 2025 (du 2025-01-01 au 2025-12-31), réparties sur les 8 régions administratives et 34 préfectures/localités présentes dans le CSV. Bonne nouvelle pour moi au moment de l'audit initial : je n'ai détecté ni valeur manquante ni doublon complet.

J'ai comparé trois modèles: régression logistique, Random Forest et XGBoost avec une séparation stratifiée 80/20. Sur cette exécution, c'est XGBoost qui obtient le meilleur F1 pondéré (0,928), suivi de très près par la régression logistique (0,927). Ces scores sont élevés, et je tiens à le souligner moi-même avant qu'on me le fasse remarquer : il faut les interpréter avec prudence, puisque le jeu de données est synthétique et que le niveau de risque a été construit à partir des mêmes facteurs environnementaux que ceux utilisés pour prédire.

Plan du rapport

Partie	Contenu
1	Compréhension métier et objectifs
2	Compréhension et qualité des données
3	Préparation et prévention de la fuite de données
4	Modélisation et évaluation
5	Interprétation, recommandations et limites
6	Déploiement, reproductibilité et références

1. Compréhension métier

1.1 Ma problématique de départ

Le paludisme est une maladie dont on sait qu'elle est fortement liée au contexte climatique : les précipitations, l'humidité, la présence d'eau stagnante et la température influencent directement les conditions de reproduction des moustiques vecteurs. C'est ce lien que j'ai voulu explorer à travers ce projet, en me posant la question suivante :

Comment estimer le niveau de risque de paludisme par période et par territoire, pour aider un centre de santé à anticiper les pics de consultation ?

1.2 Ce que je cherchais à accomplir

- Construire une base d'analyse au niveau des régions et préfectures de Guinée pour l'année 2025.
- Décrire les distributions des variables météorologiques et environnementales.
- Comparer plusieurs algorithmes de classification supervisée.
- Identifier les facteurs environnementaux qui pèsent le plus dans les décisions du modèle.
- Poser une base reproductible, que je pourrai réutiliser plus tard pour un tableau de bord Streamlit.

1.3 À quoi ça pourrait servir, concrètement

Dans l'idéal, une alerte de niveau élevé pourrait aider un centre de santé à anticiper ses stocks de tests et de traitements, à organiser ses équipes, ou à renforcer ses actions de sensibilisation en amont. Je veux être clair là-dessus : mon modèle ne remplace en aucun cas un diagnostic médical, ni un système officiel de surveillance épidémiologique. Il ne pourrait, au mieux, servir que d'outil d'aide à l'anticipation et seulement après validation par des autorités sanitaires compétentes.

1.4 Comment j'ai défini la réussite du projet

1. Respecter une séparation stricte entre apprentissage et test.
2. Comparer au moins trois modèles avec des métriques adaptées à un problème multi-classes.
3. Éviter d'utiliser des variables qui révèlent directement la cible (fuite de données).
4. Interpréter mes résultats avec transparence, en tenant compte du caractère synthétique des données.

2. Compréhension des données

2.1 D'où viennent mes données

Le fichier paludisme.csv m'a été fourni dans le cadre du projet. Il s'agit d'un jeu de données synthétique, préparé spécifiquement pour cet exercice, dont la structure reprend le contexte du sujet : conditions météo, contexte géographique et classe de risque. Je précise, pour éviter toute ambiguïté, que ces données ne doivent pas être présentées comme des observations réellement collectées par l'OMS, HDX ou Open-Meteo.

Élément	Valeur
Nombre de lignes	5 000
Période	2025-01-01 - 2025-12-31
Régions administratives	8
Préfectures/localités	34
Valeurs manquantes	0
Doublons complets	0
Variable cible	niveau_risque

2.2 Comment j'ai organisé les variables

Pour m'y retrouver, j'ai regroupé les 24 colonnes du fichier par grandes familles :

Groupe	Variables principales	Rôle
Identification	id_observation, date, annee, mois, semaine	Repérage temporel et traçabilité
Géographie	region_administrative, prefecture, latitude, longitude	Localisation de l'observation
Climat	temperature_moyenne_c, temperature_min_c, temperature_max_c	Conditions thermiques
Pluie	precipitation_mm, precipitation_7j_mm, precipitation_30j_mm, jours_pluie_7j	Humidité et accumulation des pluies
Environnement	humidite_relative_pct, humidite_sol_pct, indice_eau_stagnante	Conditions favorables aux vecteurs
Cible	niveau_risque	faible, moyen ou eleve
Contrôle	cas_paludisme_simules, taux_incidence_simule_pour_1000	Résultats simulés, exclus du modèle

2.3 Ce que l'analyse exploratoire m'a montré

La distribution de ma cible est déséquilibrée, mais les trois classes restent toutes représentées de façon significative. La classe faible domine, suivie de la classe élevée puis de la classe moyenne. Cette observation m'a conduit à pondérer les classes lors de l'apprentissage, pour éviter que le modèle ne néglige les catégories minoritaires.

Niveau	Effectif	Proportion
faible	2 157	43,1 %
elevé	1 608	32,2 %
moyen	1 235	24,7 %




Figure 1 - Répartition de la variable cible.




Figure 2 - Répartition relative du risque par région.

3. Préparation des données

3.1 Nettoyage et transformations que j'ai appliqués

5. Lecture du CSV avec un encodage UTF-8 compatible avec les accents.
6. Conversion de la date en type datetime et création de la variable jour_annee.
7. Vérification des valeurs manquantes et des doublons.
8. Séparation de la cible niveau_risque et encodage des classes avec LabelEncoder.
9. Imputation médiane pour les variables numériques, et par la modalité la plus fréquente pour les catégories.
10. Standardisation des variables numériques et encodage One-Hot des variables catégorielles.

3.2 Pourquoi j'ai exclu certaines variables

J'ai volontairement exclu les variables cas_paludisme_simules et taux_incidence_simule_pour_1000. Ce sont des résultats sanitaires simulés, beaucoup trop proches de la façon dont la classe niveau_risque a elle-même été construite. Si je les avais gardées, mes performances auraient été artificiellement gonflées, et le modèle n'aurait plus correspondu à une vraie prédiction anticipée fondée uniquement sur l'environnement, ce qui aurait trahi l'objectif même du projet.

J'ai pris soin d'ajuster mon préprocesseur uniquement sur le sous-ensemble d'entraînement, à l'intérieur de pipelines scikit-learn, pour garder le jeu de test totalement indépendant au moment de l'évaluation finale.

3.3 Les variables que j'ai finalement utilisées

Côté variables numériques, j'ai gardé le mois, la semaine, les coordonnées géographiques, les températures, les précipitations, l'humidité, le vent, les jours de pluie, l'humidité du sol, l'indice d'eau stagnante et le jour de l'année. Côté variables catégorielles, j'ai conservé la région administrative, la préfecture et la zone climatique.




Figure 3 — Corrélations entre variables numériques.

4. Modélisation

4.1 Mon protocole expérimental

J'ai séparé mes données en 80 % pour l'entraînement et 20 % pour le test, avec une stratification sur la variable cible pour préserver les proportions de chaque classe. J'ai fixé la graine aléatoire à 42 afin que mon expérience reste reproductible d'une exécution à l'autre. J'ai appliqué une pondération balanced à la régression logistique et à la forêt aléatoire ; pour XGBoost, j'ai calculé des poids d'observation à partir de la distribution du jeu d'entraînement.

4.2 Les trois algorithmes que j'ai comparés

Modèle	Principe	Pourquoi je l'ai choisi
Régression logistique	Modèle linéaire multiclassés	Référence interprétable et rapide à entraîner
Random Forest	Ensemble d'arbres avec agrégation	Capte des relations non linéaires et donne des importances de variables
XGBoost	Boosting d'arbres successifs	Généralement performant sur des relations complexes

4.3 Les métriques que j'ai suivies

- Accuracy : proportion globale de prédictions correctes.
- Précision : proportion des alertes d'une classe qui sont effectivement correctes.
- Rappel : capacité du modèle à retrouver les observations réellement présentes dans une classe.
- F1 : compromis entre précision et rappel.
- ROC-AUC OvR pondéré : capacité de séparation multiclassés, calculée en one-vs-rest.

4.4 Ce que mes résultats donnent

Modèle	Accuracy	Précision	Rappel	F1	ROC-AUC
Régression logistique	0,926	0,928	0,926	0,927	0,991
Random Forest	0,916	0,922	0,916	0,918	0,990
XGBoost	0,927	0,929	0,927	0,928	0,991

Sur cette exécution, c'est XGBoost qui l'emporte selon le F1 pondéré. Mais l'écart avec la régression logistique est faible, et c'est un point que je tiens à souligner moi-même : je ne voulais pas choisir un modèle uniquement sur la base de l'accuracy. Pour une utilisation en contexte sanitaire, je pense qu'il faudrait analyser séparément le rappel de la classe

élevé et le coût réel des faux négatifs avant toute décision opérationnelle.




Figure 4 — Comparaison des métriques sur le jeu de test.

4.5 Comment je lis ces performances

- La régression logistique m'a donné une excellente référence, en plus d'être plus simple à expliquer à quelqu'un qui ne fait pas de data science.
- Random Forest obtient un score un peu inférieur dans cette configuration, mais je pense qu'elle garde un intérêt pour analyser les interactions entre variables.
- XGBoost arrive en tête sur le F1 pondéré, sans que cet écart soit suffisant pour affirmer une réelle supériorité en conditions réelles.
- Ces performances élevées ne me surprennent pas complètement : la classe synthétique a été construite à partir des mêmes variables environnementales que celles que j'utilise pour prédire.

4.6 Ce que la matrice de confusion révèle

La matrice de confusion de mon meilleur modèle permet de voir précisément où se situent les erreurs entre les niveaux faible, moyen et élevé. Dans un vrai système d'alerte, je pense que les confusions entre moyen et élevé mériteraient une attention particulière, car elles influencent directement la façon dont les ressources seraient préparées sur le terrain.




Figure 5 — Matrice de confusion du modèle XGBoost.

4.7 Les variables qui pèsent le plus

L'analyse d'importance de XGBoost place l'indice d'eau stagnante en première position, suivi par les précipitations cumulées sur 7 jours. Viennent ensuite la zone climatique, les précipitations sur 30 jours et certaines variables géographiques. Ce classement est cohérent avec mon hypothèse de départ, mais je garde en tête qu'une importance de modèle ne prouve pas à elle seule une causalité médicale.

Variable transformée	Importance
indice_eau_stagnante	0,205
precipitation_7j_mm	0,090
zone_climatique_montagneux	0,080
precipitation_30j_mm	0,062
region_administrative_Labé	0,043
prefecture_Koundara	0,027
latitude	0,025
region_administrative_Kindia	0,022
prefecture_Boké	0,021
region_administrative_Mamou	0,019

5. Interprétation et recommandations

5.1 Ce que j'en retiens sur le plan métier

Mon modèle suggère que les indicateurs d'accumulation de pluie et d'eau stagnante sont particulièrement utiles pour distinguer les niveaux de risque, du moins dans ce jeu synthétique. J'ai aussi remarqué que les régions forestières et côtières présentent des profils distincts dans les variables simulées. Je pense que ces résultats peuvent servir à formuler des hypothèses pour une future collecte de données réelles, mais je ne les utiliserais jamais pour classer une population ou déclencher seul une intervention sanitaire.

5.2 Ce que je recommanderais pour la suite

11. Valider le modèle avec des données sanitaires réelles et datées, fournies par les services compétents.
12. Ajouter des variables retardées : consultations des semaines précédentes, couverture des campagnes, accès aux soins, densité de population.
13. Évaluer explicitement le rappel de la classe élevée et définir un seuil d'alerte selon le coût réel des faux négatifs.
14. Comparer les performances par région et par préfecture, pour repérer les zones où le modèle généralise moins bien.
15. Documenter chaque nouvelle version du jeu de données et du modèle sur GitHub, avec des messages de commit explicites.

5.3 Les limites éthiques que je garde en tête

- Ne pas présenter ce CSV synthétique comme une mesure officielle de l'incidence du paludisme.
- Ne jamais utiliser ce modèle pour un diagnostic individuel.
- Protéger toute donnée de santé réelle et supprimer les informations directement identifiantes.
- Faire valider les indicateurs et les seuils par des professionnels de santé publique avant tout usage réel.

6. Déploiement et reproductibilité

6.1 Comment j'ai organisé mon dépôt

Dossier/fichier	Rôle
README.md	Contexte, installation, méthode, résultats et limites
data/raw/	Données brutes ou liens vers les sources
data/processed/	Données nettoyées et prêtes pour l'analyse
notebooks/	Notebook d'exploration et notebook de modélisation
src/	Prétraitement, entraînement et prédiction
models/	Modèles sérialisés après validation
app/app.py	Application Streamlit locale
rapport/	Rapport final et ressources visuelles

6.2 L'application Streamlit que j'ai construite

J'ai développé une application Streamlit qui permet de sélectionner une région, une préfecture et des conditions météorologiques, puis d'afficher la classe de risque estimée avec les probabilités associées. J'ai fait en sorte que l'interface rappelle clairement la nature expérimentale du modèle, les variables utilisées et le caractère synthétique des données.

6.3 Comment reproduire mon analyse

- 16.Placer le CSV dans data/raw/ (ou adapter le chemin DATA_PATH dans les notebooks).
- 17.Installer les dépendances listées dans requirements.txt (pandas, numpy, matplotlib, seaborn, scikit-learn, xgboost, streamlit...).
- 18.Exécuter les notebooks dans l'ordre, sans modifier la séparation train/test.
- 19.Conserver le tableau des résultats, les matrices de confusion et l'analyse d'importance générés par src/train.py.
- 20.Documenter la version des paquets utilisée et la graine aléatoire (42) pour garder l'expérience reproductible.

Conclusion générale

Ce travail m'a permis de construire, de bout en bout, un pipeline de classification supervisée en suivant la méthodologie CRISP-DM : compréhension métier, compréhension des données, préparation, modélisation, évaluation et déploiement. Le code que j'ai écrit est directement adapté au CSV fourni et compare les trois algorithmes demandés dans le cahier des charges. Mon analyse met en avant l'intérêt des précipitations cumulées, de l'humidité et de l'indice d'eau stagnante pour distinguer les classes de risque dans ce jeu synthétique.

Si je devais résumer ce que je retiens de ce projet, ce serait avant tout une leçon méthodologique : avant de chercher le modèle le plus complexe ou le score le plus élevé, il faut d'abord s'assurer de la qualité du protocole, de l'absence de fuite de données, et de l'adéquation des métriques choisies à la décision métier qu'elles doivent éclairer. La prochaine étape, si ce projet devait continuer, serait de remplacer les données synthétiques par des données réelles validées, de recalibrer le modèle en conséquence, et d'organiser une évaluation avec de vrais utilisateurs de terrain.

Références et sources consultées

- 21.Université Kofi Annan de Guinée, Catalogue de projets individuels — Fouille de Données M1, année académique 2025–2026, sujet P06.
- 22.Fichier fourni : paludisme.csv, jeu synthétique utilisé pour cette étude.
- 23.Notebook fourni : churnML_1786568192001.ipynb, consulté comme exemple de structure d'analyse et de comparaison de modèles.
- 24.Brief fourni dans le projet : consignes CRISP-DM et structure recommandée du dépôt GitHub.
- 25.Sources envisagées dans le brief, à vérifier avant toute utilisation réelle : OMS/HDX pour les données sanitaires et Open-Meteo pour les historiques météorologiques.

Annexe - rappel des fichiers livrés

Fichier	Description
paludisme.csv	Jeu de données synthétique de 5 000 observations
paludisme_meteo_guinee_2025_adapte.ipynb	Notebook d'exploration et de modélisation
rapport_paludisme_guinee_2025.docx	Présent rapport Word